

Pesquisa Individual – Projeto dIscovery / Residência BRISA

Integrante: Gabryel Alvarenga Fernandes

Tema de pesquisa: Web Scraping, Coleta de Dados e Limitações Éticas/Legais

Projeto: dIscovery – Detecção de Golpes e Fraudes Digitais em Redes Sociais e Mensagerias

Programa: Residência BRISA – Instituto de Informática / UFG

O presente documento apresenta uma síntese dos dados analisados direcionados aos objetivos (boas práticas para coleta de dados no projeto, riscos e limitações que precisam ser documentados, recomendações para manter aderência à LGPD). Partindo dessa ótica, observa-se que o volume de dados online teve um crescimento exponencial, o que impulsionou os avanços na coleta automatizada de dados (web scraping) para fins acadêmicos, governamentais e comerciais, viabilizando análises em larga escala. Contudo, tais práticas envolvem limitações técnicas, riscos éticos e obrigações legais, especialmente no contexto brasileiro regulado pela Lei Geral de Proteção de Dados Pessoais (LGPD – Lei nº 13.709/2018).

Para princípios de desenvolvimento de aplicações em geral, boas práticas de programação são conceitos basilares para se atingir resultados satisfatórios. Tais práticas respeitam um conjunto de regras claras e bem estabelecidas. No presente contexto, principalmente, é importante ressaltar:

1. A priorização de APIs oficiais em detrimento do scraping direto.
2. Respeitar arquivos robots.txt e os termos de serviço.
3. Implementar limites de requisição e intervalos entre acessos.
Registrar logs de coleta, fontes e datas.
4. Realizar anonimização ou pseudonimização dos dados.
5. Armazenar dados de forma segura e com controle de acesso.
Definir prazos de retenção e descarte dos dados.

Esse conjunto de regras resguarda de forma efetiva todo o processo de desenvolvimento nos âmbitos jurídico e ético, uma vez que existem incontáveis riscos, tais como: violação dos termos de uso das plataformas, tratamento indevido de dados pessoais sem base legal adequada e sanções administrativas previstas na LGPD, como advertências, multas e bloqueio do tratamento de dados, sendo esses apenas alguns dos riscos associados ao web scraping.

Projetos de coleta de dados podem se apoiar em bases legais, uma vez que, conforme a LGPD, dados pessoais continuam sendo dados pessoais mesmo quando estão publicamente acessíveis. Portanto, a manipulação de tais dados deve considerar aspectos como: consentimento do titular, cumprimento de obrigação legal, execução de políticas públicas e pesquisa, quando observados procedimentos de anonimização sempre que possível.

Limitações técnicas apresentam complexidade ainda maior do que as jurídicas citadas acima, uma vez que, impulsionada pelo mercado, a coleta de dados se tornou alvo de interesse de diversas organizações privadas, que mantêm os dados coletados armazenados de forma rigorosa, constituindo, assim, boa resiliência no mercado digital. Portanto, foram impostas algumas barreiras que devem ser superadas seguindo as normativas estabelecidas para acessar a informação de interesse. Entre muitas, destacam-se:

1. Rate limit: restrições impostas pelos servidores quanto ao número de requisições em determinado período.
2. Bloqueios e CAPTCHAs: mecanismos para identificar e impedir acessos automatizados.
3. Mudanças no layout das páginas: alterações frequentes no HTML podem tornar scrapers obsoletos.
4. Dados incompletos ou enviesados: conteúdos personalizados por usuário, localização ou histórico de navegação podem comprometer a representatividade dos dados.
5. Dependência de plataformas: a interrupção de serviços ou mudanças nos termos de uso podem inviabilizar a continuidade do projeto.

Essas limitações devem ser documentadas de forma transparente nos projetos de pesquisa ou desenvolvimento.

Cientes de todas as implicações técnicas, jurídicas e éticas, fica a cargo dos desenvolvedores aplicar as técnicas de scraping mais eficientes para obtenção de resultados satisfatórios. Como citado anteriormente, houve muito incentivo no desenvolvimento de técnicas de coleta de dados, o que levou a métodos mais seguros e eficazes, que, de forma resumida, implicam em web scraping em páginas públicas e redes sociais e coleta de dados de mensagens por arquivos exportados (.txt).

Em redes sociais, a coleta tende a ser mais complexa devido ao uso intensivo de JavaScript dinâmico, autenticação, personalização de conteúdo e mecanismos anti-bot. Sempre que possível, recomenda-se o uso de APIs oficiais, que oferecem maior estabilidade técnica e menor risco jurídico.

Aplicações de mensageria, como WhatsApp e Telegram, permitem a exportação de conversas em arquivos de texto (.txt). Esses arquivos podem ser utilizados em análises de linguagem natural, estudos de interação social e mineração de dados textuais. Apesar de tecnicamente simples, essa forma de coleta exige cuidados adicionais, pois geralmente envolve dados pessoais e sensíveis, exigindo avaliação rigorosa da base legal para o tratamento, anonimização e limitação da finalidade.

As bibliotecas BeautifulSoup, Scrapy e Selenium, além de scripts personalizados, são as ferramentas mais populares atualmente no mercado, por consequência entregando resultados mais satisfatórios.

Retornando à Lei Geral de Proteção de Dados Pessoais (LGPD), esta estabelece normas para a proteção e o tratamento de dados pessoais em território nacional, bem como a proteção de direitos fundamentais, particularmente a privacidade, a honra e a intimidade. A LGPD também alterou os artigos 7º e 16º do chamado Marco Civil da Internet, lei federal que traz normas legais referentes ao uso da internet no território brasileiro. Sendo assim, a lei exige que métodos sejam adotados para manter o maior índice de aderência às cláusulas nele estabelecidas, tais como:

1. Mapear os dados coletados e identificar se são dados pessoais.
2. Definir claramente o papel do controlador e do operador.
3. Documentar a base legal utilizada para o tratamento.
4. Aplicar o conceito de privacy by design e by default.
5. Elaborar políticas internas de uso e proteção de dados.
6. Consultar orientações e guias da Autoridade Nacional de Proteção de Dados (ANPD).

O uso de web scraping e da coleta de dados de mensagens oferece grande potencial analítico, mas exige atenção rigorosa às limitações técnicas, aos riscos éticos e às exigências legais impostas pela LGPD. A adoção de boas práticas, aliada à documentação transparente dos procedimentos e à observância dos princípios de proteção de dados, é fundamental para garantir projetos tecnicamente viáveis, eticamente responsáveis e juridicamente seguros.

Referências de Pesquisa:

<https://www.gov.br/anpd/pt-br/centrais-de-conteudo/documentos-tecnicos-orientativos>

https://www.planalto.gov.br/ccivil_03/_Ato2015-2018/2018/Lei/L13709.htm

<https://arxiv.org/abs/2308.02231>

<https://arxiv.org/abs/2410.23432>

<https://kinsta.com/pt/blog/o-que-e-web-scraping/>

<https://www.smile-comfort.com/en/media/ethical-guidelines-for-web-scraping>

<https://jus.com.br/artigos/87950/web-sscraping-na-lei-geral-protecao-de-dados-pessoais>

https://www.ndi.org/sites/default/files/247805_NDI_Social%20Media%20Monitoring%20Guide_Portuguese.pdf

<https://www.gov.br/anpd/pt-br/aceso-a-informacao/perguntas-frequentes/perguntas-frequentes>