

## Modelo de Documento – Pesquisa Individual

### Projeto dIScovery (Residência BRISA)

#### 1. Identificação

Nome do integrante: Vitória Sofia Barbosa Pereira

Tema de pesquisa: Modelos de IA Leves para Detecção de Fraudes Textuais

Projeto: dIScovery – Detecção de Golpes e Fraudes Digitais

Programa: Residência BRISA

Data: 22/12

#### 2. Visão Geral do Tema

Foi pesquisado sobre modelos leves de IA para identificar conteúdos suspeitos e detectar os padrões básicos de golpes e fraudes digitais disseminados em redes sociais, mensagens e páginas web, com foco em conteúdos públicos.

#### 3. Relação com o Projeto

**RF03 – Classificador de Padrões Textuais:** O estudo e aplicação de modelos como Naive Bayes, Regressão Logística e DistilBERT viabilizam a criação de um classificador textual que analisa mensagens, postagens e conteúdos web, atribuindo-lhes uma classificação de risco ou tipo de golpe.

- O DistilBERT amplia a capacidade de detecção ao capturar relações semânticas, mesmo quando o texto não contém palavras-chave explícitas

**RF01 – Coleta de Conteúdo:** Embora o foco do tema não seja a coleta em si, o classificador estudado é projetado para operar sobre textos coletados por scrapers ou arquivos .txt. Ele define os requisitos de pré-processamento textual, garantindo que os dados coletados possam ser corretamente tokenizados, analisados e classificados pelos modelos de IA.

**RF02 – Taxonomia de Fraudes:** A classificação textual depende de uma taxonomia bem definida de golpes.

Os modelos estudados podem ser treinados para:

- Classificação binária (golpe vs. não golpe)
- Classificação multiclasse (tipos específicos de golpe)

**RF05 – Dashboard de Observação:** Os resultados do classificador alimentam o painel de visualização.

**RF06 – Emissão de Relatórios:** Os resultados do modelo (textos classificados, probabilidades, métricas) são insumos diretos para a geração de relatórios automáticos, apoiando ações educativas e preventivas da Anatel.

**RF07 – API Interna:** O classificador desenvolvido pode ser encapsulado em um endpoint que recebe um texto e retorna:

- Classificação
- Score de risco
- Probabilidade associada

**RN – Desempenho:** O projeto exige classificação em até 2 segundos por item textual. A escolha do DistilBERT, em vez de modelos maiores, atende à necessidade de eficiência computacional, enquanto modelos clássicos podem ser usados como fallback ou baseline, garantindo respostas rápidas mesmo em ambientes com recursos limitados.

**RN – Usabilidade:** O sistema deve ser utilizável por não especialistas.

**RN – Confiabilidade:** O projeto exige métricas claras e auditáveis.

**RN – Escalabilidade:** A arquitetura deve permitir evolução futura. A adoção de um modelo Transformer compacto possibilita:

- Evolução para versões mais robustas
- Integração futura com análise de links ou dados multimodais
- Re-treinamento com novos tipos de golpe

#### 4. Referências Pesquisadas

- *DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter* (Sanh et al., 2019): <https://arxiv.org/abs/1910.01108>
- *Robust and Accurate Phishing Detection Using Enhanced DistilBERT: A Transformer-Based Approach* (Farhan, 2025): <https://jqcsm.qu.edu.iq/index.php/journalcm/article/view/2403/1103>
- *Phishing URL Detection Using DistilBERT and Capsule Neural Networks* (Atla, 2025): <https://norma.ncirl.ie/8458/>
- *Building a High-Performance NER System for Transactional SMS: DistilBERT Fine-tuning* (Medium, 2025): <https://medium.com/@rkuma18/building-a-high-performance-ner-system-for-transactional-sms-distilbert-fine-tuning-c7134813383c>

## 5. Principais Achados

Os estudos mostram que modelos clássicos, como Naive Bayes e Regressão Logística, são úteis como baseline devido à simplicidade e rapidez, mas apresentam limitações quando as fraudes utilizam linguagem variada ou sutil. Modelos leves baseados em Transformers, como o DistilBERT, demonstram melhor capacidade de capturar contexto e relações semânticas, oferecendo maior recall e melhor desempenho geral. Entretanto, ainda exigem boa infraestrutura, dependem de bases bem rotuladas e possuem menor interpretabilidade quando comparados aos modelos tradicionais.

## 6. Insights Aplicáveis ao Projeto

Recomenda-se uma abordagem em duas camadas: modelos clássicos como baseline e DistilBERT como modelo principal de classificação. O sistema deve priorizar recall, reduzindo o risco de falsos negativos. É essencial uma base de dados diversa e alinhada à taxonomia de fraudes do projeto, além de atualização contínua do modelo. O uso de um Transformer compacto contribui para eficiência e escalabilidade, enquanto o monitoramento de métricas no dashboard reforça transparência e melhoria contínua.

## 7. Conclusão

A pesquisa evidencia que modelos clássicos são úteis como apoio inicial, mas o DistilBERT oferece melhor desempenho para detecção de fraudes textuais por compreender contexto e variações de linguagem. Priorizar recall e boas práticas de treinamento é fundamental para reduzir riscos. Assim, o uso de um modelo leve baseado em DistilBERT, aliado a métricas adequadas e atualização contínua, mostra-se alinhado aos requisitos do discovery e contribui para uma solução eficiente, prática e escalável.

## 8. Referências

SANH, Victor; DEBUT, Lysandre; CHAUMOND, Julien; WOLF, Thomas. **DistilBERT: a distilled version of BERT: smaller, faster, cheaper and lighter**. 2019. Disponível em:

<https://arxiv.org/abs/1910.01108>

FARHAN, et al. **Robust and Accurate Phishing Detection Using Enhanced DistilBERT: A Transformer-Based Approach**. Journal of Computer Science and Mathematics, 2025.

Disponível em: <https://jqcsm.qu.edu.iq/index.php/journalcm/article/view/2403/1103>

ATLA, Sri Vidya. **Phishing URL Detection Using DistilBERT and Capsule Neural Networks**. 2025. Disponível em: <https://norma.ncirl.ie/8458/>

RAVIKUMAR, R. **Building a High-Performance NER System for Transactional SMS: DistilBERT Fine-tuning**. Medium, 2025. Disponível em:

<https://medium.com/@rkuma18/building-a-high-performance-ner-system-for-transactional-sms-distilbert-fine-tuning-c7134813383c>

Ferramentas de inteligência artificial generativa foram utilizadas como apoio à pesquisa, organização conceitual e revisão textual deste trabalho. As informações obtidas foram verificadas e complementadas com fontes científicas confiáveis.